Análisis de datos de entrada y ajuste de datos a distribuciones de probabilidad

Práctica N.° 05, Simulación Computacional

Luciana Alejandra Belandria Agudelo
Código: 16000500
Ingeniería de Sistemas
Universidad de los Llanos
Villavicencio, Meta, Colombia

***Resumen*—Trabajamos con cuatro muestras de 200 tiempos entre llegadas, identificadas como A, B, C y D, y buscamos para cada una un modelo que pueda alimentar una simulación. El recorrido tuvo tres etapas. Primero resumimos cada muestra con medidas descriptivas e histogramas. Luego revisamos el orden de los datos para saber si eran independientes y si su comportamiento se mantenía en el tiempo. Al final ajustamos nueve distribuciones por máxima verosimilitud y las comparamos con SSE, AIC y BIC. Solo dos muestras resultaron IID: B, que se describe con una exponencial, y D, que sigue una lognormal. La muestra A tiene valores con forma normal pero dependientes entre sí, y en C la tasa de llegadas cae a lo largo del registro, de modo que una distribución fija no la representa.**

***Index Terms*—Datos de entrada, supuesto IID, autocorrelación, estacionariedad, máxima verosimilitud, AIC, BIC, SSE.**

I. Introducción

¿Qué distribución usar para los tiempos entre llegadas de un modelo? Antes de responder hay que verificar algo más básico. Banks recomienda comprobar primero si los datos son independientes y si su distribución se mantiene estable [1]; si alguna de las dos cosas falla, cualquier distribución ajustada describe una población que en realidad no existe.

Seguimos ese orden con las cuatro muestras de la guía [4]. Escribimos el análisis en dos notebooks de Python apoyados en NumPy, pandas, SciPy [3] y Matplotlib. El primero (`Lab5_Notebook1_Analisis_Entrada.ipynb`) cubre la descripción de las muestras y la revisión de supuestos; el segundo (`Lab5_Notebook2_Ajuste_Curvas.ipynb`) es el notebook independiente de ajuste de curvas que pide la guía, y para construirlo tomamos como referencia el tutorial de Amat [2]. Las secciones de este informe siguen las tres partes del procedimiento: descripción de las muestras, revisión de supuestos y selección del modelo.

II. Consulta previa

II-A. Estadística descriptiva

Cuando solo interesa conocer los datos que se tienen, sin generalizar a una población, se recurre a la estadística descriptiva. Sus herramientas son números que resumen el centro (media, mediana), la variabilidad (varianza, desviación estándar, coeficiente de variación), la posición (percentiles) y la forma (asimetría, curtosis), además de gráficos como el histograma. En un estudio de simulación es lo primero que se calcula, porque muestra la escala de los datos y sugiere qué familias de distribuciones vale la pena probar.

II-B. Asimetría, curtosis y percentiles

Tres medidas complementan a la media y la varianza. La asimetría, $\gamma_1 = E[(X-\mu)^3]/\sigma^3$, indica hacia qué lado se alarga la distribución: un valor positivo corresponde a una cola derecha extendida, como la de casi todos los tiempos de espera, y un valor cercano a cero corresponde a una forma simétrica. La curtosis describe el grosor de las colas; nosotros reportamos el exceso $\gamma_2 = E[(X-\mu)^4]/\sigma^4 - 3$, que es nulo para la normal y crece cuando los extremos son frecuentes. Los percentiles dividen los datos ordenados: el percentil p deja por debajo el $p\,\%$ de las observaciones, y los de orden 25, 50 y 75 forman los cuartiles Q1, Q2 y Q3.

II-C. Supuesto IID

Decir que $X_1, \ldots, X_n$ son IID equivale a afirmar dos cosas a la vez. La primera es la independencia: ninguna observación aporta información sobre otra, y en consecuencia $\mathrm{Cov}(X_i, X_j) = 0$ cuando $i \neq j$. La segunda es la idéntica distribución: todas provienen de la misma ley de probabilidad, con los mismos parámetros. Bajo este supuesto el simulador puede generar cada entrada por separado a partir de una sola distribución [1].

II-D. Proceso estocástico estacionario

Si desplazamos en el tiempo un proceso estacionario $\{X_t\}$, su distribución conjunta permanece igual; esa es la definición estricta. La versión débil pide menos: media y varianza constantes, y una covarianza entre X_t y X_{t+k} que dependa únicamente de k. Para los datos de entrada esto se traduce en ausencia de tendencias o cambios de nivel durante la observación. Un caso típico de no estacionariedad es la llegada de clientes con una tasa $\lambda(t)$ que sube y baja según la hora.

II-E. Proceso estocástico correlacionado

En un proceso correlacionado el pasado influye en el presente, y por eso la autocorrelación $\rho_k = \mathrm{Cov}(X_t, X_{t+k})/\sigma^2$ deja de ser cero para uno o más retrasos k. La recurrencia

$x_i = \alpha x_{i-1} + (1-\alpha)u_i$ produce justamente ese efecto, porque cada valor conserva una parte del anterior. Si se simula un proceso así como si fuera IID, la variabilidad de la salida queda subestimada. La alternativa es un modelo de series de tiempo, como el autorregresivo.

III. Datos y procedimiento

Cada archivo contiene 200 números positivos. Los tratamos como tiempos entre llegadas x_i; así, la i-ésima llegada sucede en $t_i = x_1 + \cdots + x_i$ y el horizonte observado mide $T = t_{200}$.

Para la parte descriptiva calculamos tamaño, extremos, media, varianza y desviación estándar con denominador $n-1$, y los cuartiles. Agregamos la asimetría, la curtosis y el coeficiente de variación $CV = s/\bar{x}$, que no pide la guía pero ayudan a anticipar la forma de cada muestra. Los histogramas usan 20 particiones.

Para revisar los supuestos construimos, en cada muestra, las cinco gráficas de la guía: autocorrelación hasta el retraso 20, con banda del 95 % igual a $\pm 1.96/\sqrt{200} = \pm 0.139$; dispersión de cada dato contra el siguiente; fracción acumulada de llegadas frente al tiempo; número de llegadas en 20 tramos iguales de $[0, T]$; y media móvil con ventana de 20 datos y límites a tres desviaciones. Las veinte gráficas aparecen en el Anexo A (Figs. 8 a 11), cada una con su lectura. En el cuerpo del informe incluimos además dos vistas conjuntas que concentran lo esencial. Como prueba adicional de estabilidad comparamos la media de la primera mitad de cada muestra con la de la segunda.

Para el ajuste estimamos por máxima verosimilitud las cinco distribuciones que exige la guía (exponencial, lognormal, normal, gamma y beta) y cuatro que escogimos por ser habituales en tiempos positivos con cola derecha: Weibull, Rayleigh, gaussiana inversa y log-logística. Fijamos en cero la localización de los modelos con soporte $[0, \infty)$ y confinamos la beta al intervalo $[0,\ 1.01\ \text{máx}\, x_i]$; sin esas restricciones el optimizador producía ajustes absurdos, entre ellos una Weibull con AIC infinito. La normal quedó libre. Sean ℓ la log-verosimilitud, p la cantidad de parámetros libres y $n = 200$; entonces

$$\text{AIC} = 2p - 2\ell, \qquad \text{BIC} = p \ln n - 2\ell, \tag{1}$$

$$\text{SSE} = \sum_{j=1}^{20} \Big(f(m_j; \hat{\theta}) - h_j \Big)^2, \tag{2}$$

con h_j la densidad empírica de la partición j y m_j su punto medio. Un valor menor indica mejor ajuste en las tres. Ordenamos los modelos por AIC, que usa cada observación y no depende de cómo se parta el histograma, y contrastamos ese orden con el BIC y el SSE.

IV. Descripción de las muestras

Lectura de la Tabla I: El tamaño es lo único que comparten: 200 datos por muestra. En lo demás aparecen dos grupos. A queda sola en el primero. Su desviación estándar equivale al 22 % de la media, que vale 0.195, apenas por encima de la mediana de 0.192; con una asimetría de -0.29 y una curtosis de 0.35, todo indica una forma de campana.

Tabla I
Descripción estadística de los conjuntos de datos A, B, C y D

Medida	**A**	**B**	**C**	**D**
Tamaño de la muestra	200	200	200	200
Mínimo	0.02096	8.516×10^{-5}	0.9267	0.1115
Máximo	0.299	1.551	6 669.85	17.97
Media	0.195	0.2054	762.39	2.060
Varianza	0.001919	0.05248	8.522×10^{5}	5.413
Desviación estándar	0.04381	0.2291	923.13	2.327
Percentil 25 % (Q1)	0.1638	0.04633	152.91	0.6343
Percentil 50 % (Q2 o mediana)	0.1921	0.1377	455.56	1.406
Percentil 75 % (Q3)	0.2301	0.2902	1 028.59	2.529
Asimetría (skewness)	-0.2917	2.425	2.501	3.184
Curtosis (exceso)	0.3475	8.208	9.363	14.48
Coef. de variación	0.2246	1.115	1.211	1.129

El segundo grupo reúne a B, C y D. Las tres tienen la media por encima de la mediana y un coeficiente de variación mayor que 1 (1.12, 1.21 y 1.13), rasgos de tiempos con cola larga a la derecha. Cada una tiene además algo propio. En B, desviación (0.229) y media (0.205) son casi iguales, igualdad que caracteriza a la exponencial. C opera en otra magnitud, con datos entre 0.93 y 6 670, media de 762 y varianza cercana a 8.5×10^5. Y D tiene las colas más gruesas: curtosis de 14.5 y un máximo de 17.97, aunque tres cuartas partes de sus datos no pasan de 2.53.

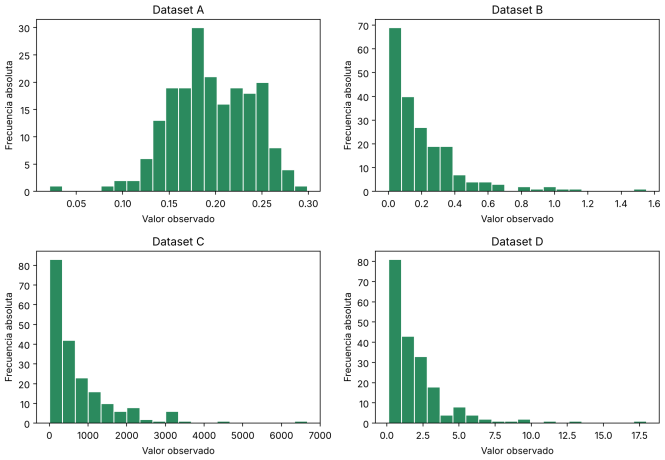


Figura 1. Histogramas de los conjuntos de datos A, B, C y D (20 particiones).

Lectura de la Fig. 1: En las gráficas se repite la división de la tabla. A forma una campana entre 0.10 y 0.30, con un único punto suelto en 0.021 que corresponde a la primera observación. B, C y D arrancan con su barra más alta pegada a cero y luego decaen. El descenso de B es gradual y regular. El de C y el de D es más brusco, y después quedan observaciones aisladas muy a la derecha: hacia 6 670 en C y hacia 18 en D. Ya con esto la normal y la Rayleigh lucen poco prometedoras para esas tres muestras. Lo que un histograma no puede revelar es el orden de los datos, y a eso dedicamos la sección siguiente.

V. Independencia y estabilidad

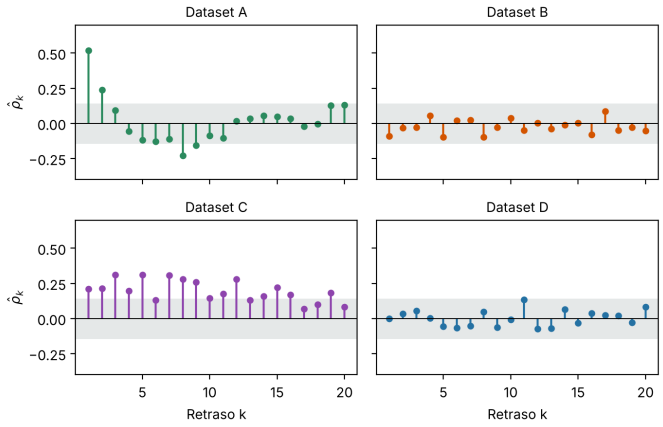


Figura 2. Autocorrelación muestral hasta el retraso 20. La franja gris marca la banda de confianza del 95 %.

Lectura de la Fig. 2: Con la autocorrelación juzgamos la independencia. A presenta el caso más evidente de dependencia: su coeficiente en el retraso 1 vale 0.517, casi el cuádruple del límite de la banda, el del retraso 2 también sobresale, y alrededor del retraso 8 hay una oscilación negativa. En el diagrama de dispersión de la Fig. 8(b) esa dependencia se ve como una nube inclinada, donde a un valor alto le sigue con frecuencia otro alto. En C sobresalen 15 de los 20 coeficientes, todos positivos y con un descenso lento; más que dependencia de corto plazo, ese patrón delata una tendencia. B y D no muestran nada fuera de la banda, con coeficientes de -0.093 y -0.003 en el primer retraso.

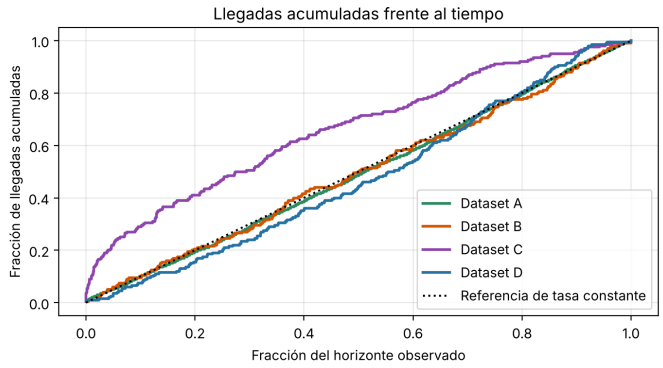


Figura 3. Fracción acumulada de llegadas frente a la fracción del horizonte observado. La línea punteada representa una tasa constante.

Lectura de la Fig. 3: Cuando la tasa de llegadas no cambia, la curva acumulada coincide con la diagonal. Así ocurre con A y B de principio a fin. D baja un poco en el tramo central y vuelve a la línea cerca del final, algo esperable en una muestra con colas tan pesadas. C es otra historia. Cuando ha transcurrido la mitad del horizonte ya acumula alrededor del 70 % de sus llegadas, y en el último tramo la curva casi no sube: los intervalos entre llegadas se alargan y la tasa cae. El conteo por tramos de la Fig. 10(d) lo confirma, con 44 llegadas en el primer tramo y entre 2 y 5 en los últimos.

Tabla II
Indicadores de independencia y estabilidad

Muestra	$\hat{\rho}_1$	**Retrasos fuera de banda**	$\bar{x}_{1ª\ \text{mitad}}$	$\bar{x}_{2ª\ \text{mitad}}$	**¿IID?**
A	0.517	1, 2, 8, 9	0.199	0.191	No (correl.)
B	-0.093	ninguno	0.205	0.206	Sí
C	0.210	15 de 20	417.6	1107.2	No (no estac.)
D	-0.003	ninguno	2.283	1.838	Sí (aprox.)

Lectura de la Tabla II: En la tabla juntamos las dos figuras con la comparación de medias por mitades. Para B la conclusión es inmediata: nada fuera de la banda y dos mitades casi idénticas (0.205 y 0.206). A tiene mitades igual de parecidas (0.199 y 0.191), y su media móvil nunca rompe los límites (Fig. 8(e)), así que su comportamiento es estable; lo que le impide ser IID es la correlación. En C la media de la segunda mitad es 2.65 veces la de la primera (1 107 frente a 418), y su media móvil asciende sin pausa desde unos 50 hasta más de 2 000 (Fig. 10(e)), de modo que la descartamos como estacionaria. D requirió más cuidado. Sus mitades difieren algo (2.28 y 1.84) y su media móvil salta al final (Fig. 11(e)), pero ese salto lo causan dos valores extremos, 11.1 y 17.97, ubicados en las últimas posiciones, no un cambio de nivel que se sostenga. Por eso la aceptamos como IID. En resumen, B y D son las únicas muestras que podemos simular directamente con una distribución ajustada.

VI. Selección de distribuciones

En las Tablas III a VI usamos la notación de `scipy.stats`: θ para la escala, μ para la localización, y a, b, c y σ para los parámetros de forma. La negrita señala el mejor valor de cada métrica.

VI-A. Muestra A

Tabla III
Bondad de ajuste para el conjunto de datos A

Distribución	**Parámetros**	**SSE**	**AIC**	**BIC**
Exponencial	$\theta = 0.195$	340.47	-251.82	-248.52
Lognormal	$\sigma = 0.275$, $\theta = 0.189$	36.97	-611.09	-604.49
Normal	$\mu = 0.195$, $\theta = 0.0437$	29.15	**−680.59**	**−673.99**
Gamma	$a = 16.18$, $\theta = 0.01206$	**28.24**	-647.34	-640.75
Beta	$a = 5.902$, $b = 3.234$	29.36	-675.74	-669.14
Weibull	$c = 5.071$, $\theta = 0.212$	32.43	-679.36	-672.76
Rayleigh	$\theta = 0.1413$	185.20	-497.00	-493.70
Gaussiana inversa	$\mu = 0.08962$, $\theta = 2.176$	48.06	-583.42	-576.83
Log-logística	$c = 7.293$, $\theta = 0.1927$	33.42	-655.44	-648.85

Lectura de la Tabla III: Por un margen pequeño, la normal ocupa el primer lugar con un AIC de -680.59; detrás quedan la Weibull con -679.36 y la beta con -675.74, y el BIC repite ese orden. ¿Por qué tan parejas? Con $c = 5.07$ la Weibull adopta forma de campana, y lo mismo le sucede a la beta con $a = 5.90$ y $b = 3.23$. En el fondo de la tabla aparecen la Rayleigh (-497.00) y la exponencial (-251.82). Esta última concentra la probabilidad junto a cero, una región donde A casi no tiene datos. El SSE favorece a la gamma (28.24 frente a 29.15 de la normal), pero la gamma ocupa el quinto lugar en AIC y en BIC, lo que nos lleva a pensar que esa ventaja proviene de cómo caen los datos en las particiones.

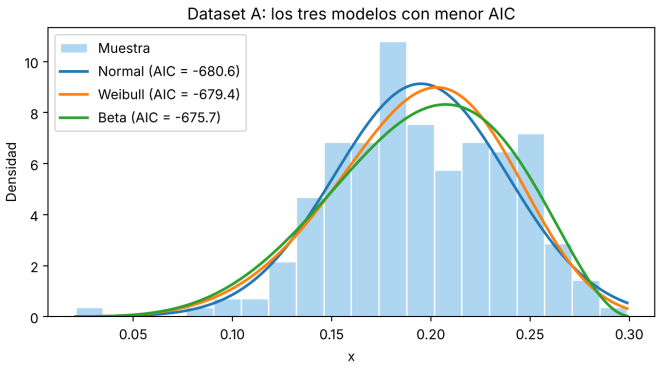


Figura 4. Muestra A con los tres modelos de menor AIC superpuestos.

Lectura de la Fig. 4: Sobre el histograma las tres curvas apenas se distinguen. Solo en los extremos se separan: la Weibull se carga un poco a la izquierda y la beta corta antes su cola derecha, porque su soporte acaba en $1.01\,\text{máx}\,x_i$. El dato de 0.021 queda fuera del alcance de todas.

Modelo elegido para A: Escogemos la normal con $\mu = 0.195$ y $\sigma = 0.0437$. Obtiene el menor AIC y el menor BIC, usa dos parámetros y concuerda con una muestra prácticamente simétrica. El riesgo de que produzca tiempos negativos es despreciable: 4×10^{-6}. La advertencia importante va por otro lado. Generar normales independientes eliminaría la correlación que vimos en la Fig. 2; por eso, en la simulación, conviene usarla como marginal de un proceso AR(1).

VI-B. Muestra B

Lectura de la Tabla IV: En esta muestra los criterios discrepan. El AIC pone primero a la Weibull (-232.26), muy cerca de la gamma (-232.10) y de la exponencial (-231.13). El BIC castiga con más fuerza cada parámetro adicional y prefiere la exponencial (-227.83). La clave está en las formas estimadas, $c = 0.91$ para la Weibull y $a = 0.86$ para la gamma: ambas rondan 1, el valor en que las dos familias se reducen a la exponencial. Las tres primeras describen, entonces, casi la misma curva, y el parámetro extra aporta muy poco. Fallan los modelos cuya densidad es nula o muy baja junto al origen. La normal y la Rayleigh quedan lejos, y la gaussiana inversa llega hasta un AIC de 151.99.

Tabla IV
BONDAD DE AJUSTE PARA EL CONJUNTO DE DATOS B

Distribución	**Parámetros**	**SSE**	**AIC**	**BIC**
Exponencial	$\theta = 0.2054$	0.4358	-231.13	$\mathbf{-227.83}$
Lognormal	$\sigma = 1.437$, $\theta = 0.104$	2.326	-188.73	-182.14
Normal	$\mu = 0.2054$, $\theta = 0.2285$	11.57	-18.89	-12.29
Gamma	$a = 0.8636$, $\theta = 0.2378$	0.3158	-232.10	-225.50
Beta	$a = 0.6894$, $b = 4.115$	1.111	-207.31	-200.71
Weibull	$c = 0.9095$, $\theta = 0.1963$	**0.2762**	$\mathbf{-232.26}$	-225.67
Rayleigh	$\theta = 0.2173$	18.12	85.99	89.29
Gaussiana inversa	$\mu = 22.40$, $\theta = 0.009169$	6.528	151.99	158.58
Log-logística	$c = 1.307$, $\theta = 0.1184$	1.143	-206.65	-200.06

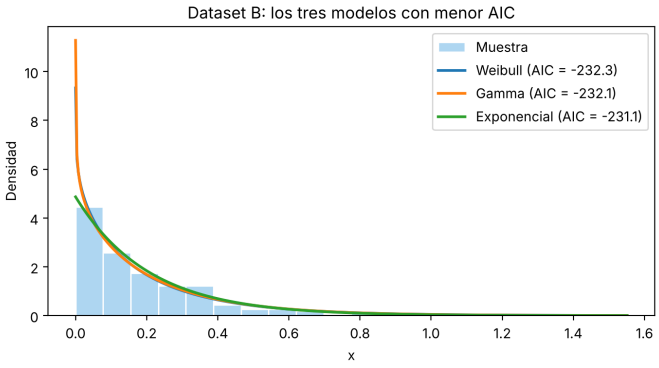


Figura 5. Muestra B con los tres modelos de menor AIC superpuestos.

Lectura de la Fig. 5: Desde el origen, las tres curvas descienden acompañando las barras. La única diferencia visible está en el primer tramo: con forma menor que 1, la densidad de la Weibull y la de la gamma crece sin límite al acercarse a cero, así que esas dos curvas arrancan por encima de la exponencial. De $x \approx 0.2$ en adelante no se pueden separar.

Modelo elegido para B: Nos quedamos con la exponencial de escala $\theta = 0.2054$, es decir, de tasa $\lambda = 4.87$. Frente a la Weibull pierde solo 1.13 unidades de AIC, menos que el umbral de 2 con el que se suele declarar equivalentes dos modelos. A su favor tiene el BIC, un único parámetro y un coeficiente de variación muestral de 1.12. Como además B es IID, el modelo corresponde a un proceso de Poisson, la opción más simple de programar.

VI-C. Muestra C

Lectura de la Tabla V: Gamma y Weibull empatan prácticamente en AIC, con $3\,040.22$ y $3\,040.81$, y el BIC no altera el orden. Sus parámetros de forma, $a = 0.71$ y $c = 0.80$, son menores que 1; eso les da más masa cerca de cero y una cola más larga que la de una exponencial. La exponencial, que equivale a fijar la forma en 1, aparece tercera a 16 unidades, distancia que ya marca una diferencia real. El SSE prefiere la Weibull y coloca a la log-logística en segundo lugar, aunque esta es quinta según el AIC. La magnitud del SSE, del orden

Tabla V
BONDAD DE AJUSTE PARA EL CONJUNTO DE DATOS C

Distribución	Parámetros	SSE	AIC	BIC
Exponencial	$\theta = 762.40$	5.978×10^{-8}	3056.59	3059.88
Lognormal	$\sigma = 1.648$, $\theta = 324.30$	6.361×10^{-8}	3084.19	3090.78
Normal	$\mu = 762.40$, $\theta = 920.80$	9.265×10^{-7}	3301.68	3308.28
Gamma	$a = 0.7062$, $\theta = 1\,080.00$	4.493×10^{-8}	**3040.22**	**3046.82**
Beta	$a = 0.5847$, $b = 4.109$	1.298×10^{-7}	3061.97	3068.57
Weibull	$c = 0.8007$, $\theta = 676.00$	2.524×10^{-8}	3040.81	3047.41
Rayleigh	$\theta = 845.30$	1.434×10^{-6}	3481.09	3484.39
Gaussiana inversa	$\mu = 19.81$, $\theta = 38.49$	3.224×10^{-7}	3310.51	3317.11
Log-logística	$c = 1.126$, $\theta = 384.40$	4.076×10^{-8}	3072.48	3079.08

Tabla VI
BONDAD DE AJUSTE PARA EL CONJUNTO DE DATOS D

Distribución	Parámetros	SSE	AIC	BIC
Exponencial	$\theta = 2.060$	0.009898	691.18	694.48
Lognormal	$\sigma = 1.019$, $\theta = 1.273$	0.006913	**675.89**	**682.49**
Normal	$\mu = 2.060$, $\theta = 2.321$	0.1175	908.33	914.93
Gamma	$a = 1.178$, $\theta = 1.749$	0.01048	689.97	696.56
Beta	$a = 0.8645$, $b = 5.872$	0.0249	739.02	745.62
Weibull	$c = 1.042$, $\theta = 2.099$	0.01066	692.55	699.14
Rayleigh	$\theta = 2.194$	0.1572	934.06	937.36
Gaussiana inversa	$\mu = 1.763$, $\theta = 1.169$	0.02549	685.40	692.00
Log-logística	$c = 1.705$, $\theta = 1.310$	**0.006011**	681.40	688.00

de 10^{-8}, no dice nada por sí sola: refleja densidades pequeñas en una escala que llega a 6 670, y solo tiene sentido compararla entre modelos.

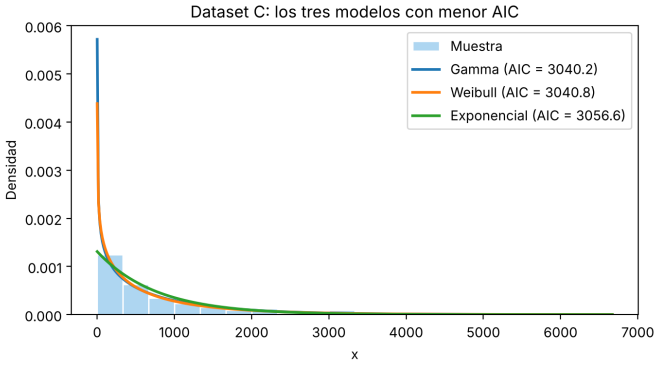


Figura 6. Muestra C con los tres modelos de menor AIC superpuestos.

Lectura de la Fig. 6: Junto al origen, la gamma y la Weibull se elevan para cubrir la primera barra; la exponencial parte más abajo y se queda corta en esa zona. Pasados los 1 000, las tres curvas se juntan y recorren la cola. El ajuste luce razonable, pero la figura oculta un hecho: los valores grandes se acumulan al final de la serie.

Modelo elegido para C: Si se exige un solo modelo, elegimos la gamma con $a = 0.706$ y $\theta = 1080$. Gana en AIC y en BIC, y su media teórica, $a\theta = 762.4$, coincide con la muestral. Defender la Weibull sería igual de válido. Con todo, la decisión pesa poco frente al hallazgo de la sección anterior. C no es estacionaria, y una gamma simulada como IID mezclaría los valores pequeños del comienzo con los grandes del final. Lo que proponemos para un modelo serio es estimar la tasa de llegadas por tramos y emplear un proceso de Poisson no estacionario, o bien ajustar una distribución diferente en cada tramo.

VI-D. Muestra D

Lectura de la Tabla VI: La lognormal registra el menor AIC (675.89) y el menor BIC (682.49). Le siguen la log-logística (681.40) y la gaussiana inversa (685.40). Esta vez la distancia de 5.5 unidades con el segundo lugar es suficiente para preferirla sin titubear. Los tres primeros modelos comparten una cola derecha más gruesa que la exponencial, justo lo que pide una muestra con curtosis de 14.5. Gamma ($a = 1.18$) y Weibull ($c = 1.04$) quedan a mitad de tabla: con forma cercana a 1 se parecen a la exponencial, y su cola decae demasiado rápido. Una vez más el SSE se aparta y elige la log-logística (0.00601, contra 0.00691 de la lognormal).

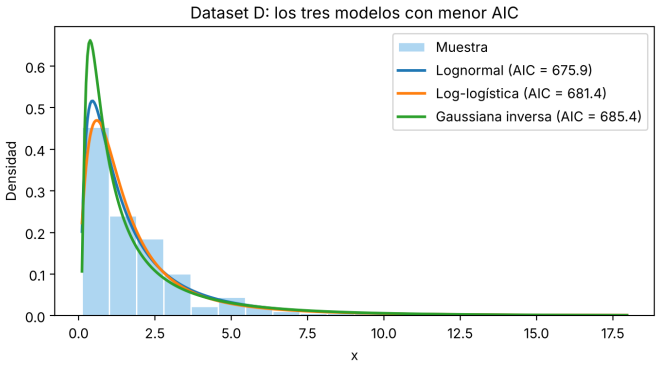


Figura 7. Muestra D con los tres modelos de menor AIC superpuestos.

Lectura de la Fig. 7: Las diferencias entre las curvas se concentran en el pico. La gaussiana inversa lo dibuja alto y estrecho cerca de 0.4, por encima de las barras; la log-logística lo deja más bajo y ancho. La lognormal se ubica entre ambas y acompaña mejor la bajada entre 1 y 3. Más allá de 5 las colas de los tres modelos prácticamente coinciden.

Modelo elegido para D: Elegimos la lognormal con $\sigma = 1.019$ y $\theta = 1.273$, lo que equivale a $\mu_{\ln} = \ln 1.273 = 0.242$. Gana en ambos criterios de información, reproduce la cola pesada y su media teórica, 2.14, queda cerca de la muestral, 2.06. El SSE de la log-logística no nos convence: con una cola tan extensa, la mayoría de las 20 particiones están casi vacías y la métrica se define en las primeras barras. Al ser D una muestra IID, la lognormal entra directamente al modelo de simulación.

VII. Conclusiones

Las medidas descriptivas acertaron en varias predicciones. El CV de B, cercano a 1, apuntaba a la exponencial, y la curtosis de D anunciaba una cola pesada. Sin embargo, quedarnos con ellas nos habría llevado a un error en A: su tabla y su histograma la hacen parecer una muestra normal sin complicaciones, y su autocorrelación de 0.52 demuestra lo contrario.

El supuesto IID solo se cumple en B y D. Para ellas recomendamos una exponencial de tasa 4.87 y una lognormal con $\sigma = 1.02$ y escala 1.27, respectivamente. En A la normal describe la forma de los datos, pero generarlos de manera independiente borraría la correlación; un proceso AR(1) con esa marginal sería más fiel. En C la gamma resulta la mejor de las nueve opciones, aunque lo que de verdad hay que modelar es la caída de la tasa de llegadas.

Respecto a las métricas, AIC y BIC eligieron el mismo modelo en A, C y D. En B discreparon, sin consecuencias, porque las diferencias eran mínimas. El SSE fue el menos estable de los tres criterios: depende de cómo se parta el histograma y en A, C y D señaló un modelo distinto al de los criterios de información.

Apéndice A
Gráficas completas del análisis de datos de entrada

Las Figs. 8 a 11 reúnen, para cada muestra, las cinco gráficas de la sección 5.2 de la guía: (a) correlación de retraso, (b) diagrama de dispersión, (c) patrón de tiempos de llegada, (d) conteo de llegadas por intervalo y (e) media móvil. El primer panel de cada figura muestra la secuencia de datos en el orden en que se registraron.

Lectura de la Fig. 8: En A conviven dos cosas. La dependencia se nota en (a), donde los retrasos 1 y 2 sobresalen de la banda, y en (b), donde los puntos forman una nube inclinada hacia arriba. La estabilidad se nota en los otros tres paneles: el patrón de llegadas (c) va pegado a la diagonal, cada intervalo recibe entre 9 y 12 llegadas (d) y la media móvil (e) oscila alrededor de 0.195 sin tocar los límites. La muestra es estable pero no independiente.

Lectura de la Fig. 9: B no muestra señales de dependencia ni de cambio. Ningún coeficiente sale de la banda en (a). En (b) los puntos se agolpan cerca del origen, pero eso se debe a la asimetría de los datos y no a una relación entre valores consecutivos. El patrón de llegadas (c) sigue la diagonal, los conteos (d) varían entre 5 y 15 sin tendencia y la media móvil (e) se mantiene dentro de sus límites. Todo apunta a una muestra IID.

Lectura de la Fig. 10: La secuencia de C crece a la vista: los datos del comienzo apenas se separan de cero y los del final superan con frecuencia $2\,000$. Los demás paneles cuentan la misma historia. La autocorrelación (a) queda positiva en casi todos los retrasos, el patrón de llegadas (c) se curva por encima de la diagonal, el conteo (d) baja de 44 llegadas en el primer intervalo a entre 2 y 5 en los últimos, y la media móvil (e) sube de forma sostenida. La tasa de llegadas disminuye con el tiempo; C no es estacionaria.

Lectura de la Fig. 11: En D la autocorrelación (a) se queda dentro de la banda y el diagrama de dispersión (b) no muestra relación entre valores consecutivos. El patrón de llegadas (c) se aparta levemente de la diagonal en la parte central, y los conteos (d) varían más que en B, algo normal con una cola tan pesada. El salto de la media móvil al final (e) coincide con los dos valores extremos de la serie, 11.1 y 17.97, en las últimas posiciones. No vemos un cambio de nivel sostenido, así que tratamos a D como IID.

Referencias

[1] J. Banks, *Handbook of Simulation: Principles, Methodology, Advances, Applications, and Practice*. New York, NY, USA: John Wiley & Sons, 1998, cap. 3.

[2] J. Amat Rodrigo, "Ajuste y selección de distribuciones con Python," Ciencia de Datos, 2021. [En línea]. Disponible: https://www.cienciadedatos.net/documentos/pystats01-ajuste-distribuciones-python.html. doi: 10.5281/zenodo.10006330.

[3] P. Virtanen *et al.*, "SciPy 1.0: Fundamental algorithms for scientific computing in Python," *Nature Methods*, vol. 17, pp. 261–272, 2020.

[4] A. A. Cruz Roa, "Análisis de datos de entrada y ajuste de datos a distribuciones de probabilidad," Guía de laboratorio FO-DOC-112, Simulación Computacional, Universidad de los Llanos, 2024.

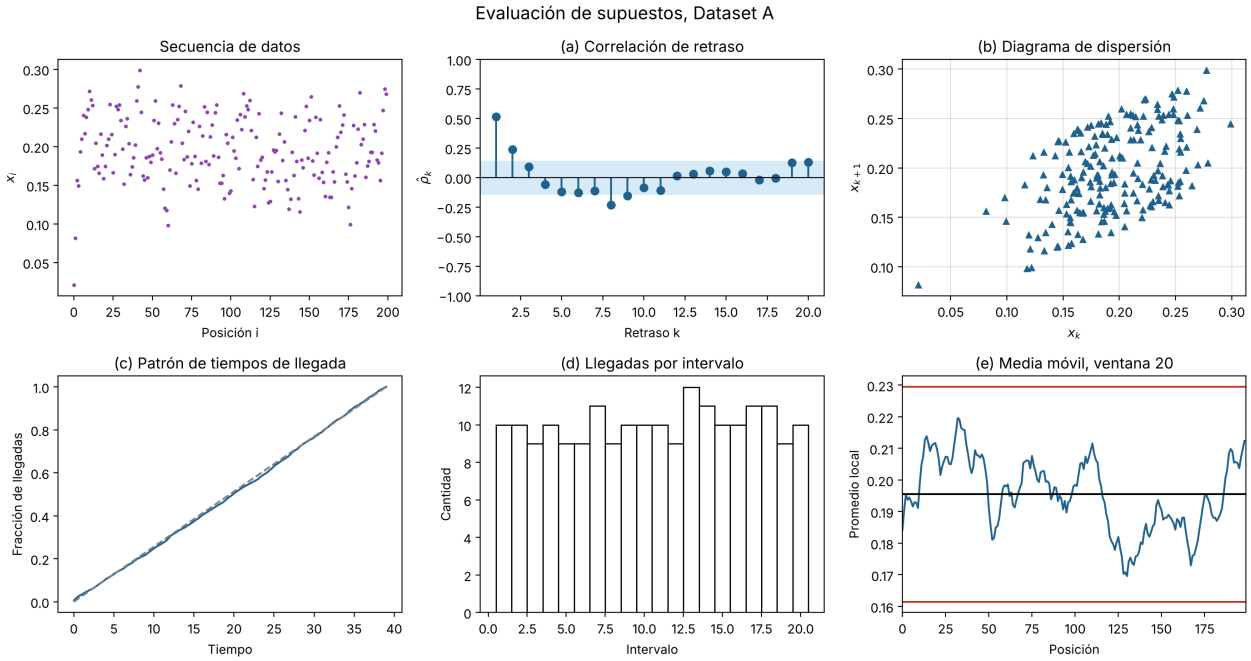


Figura 8. Gráficas de la sección 5.2 para el conjunto A.

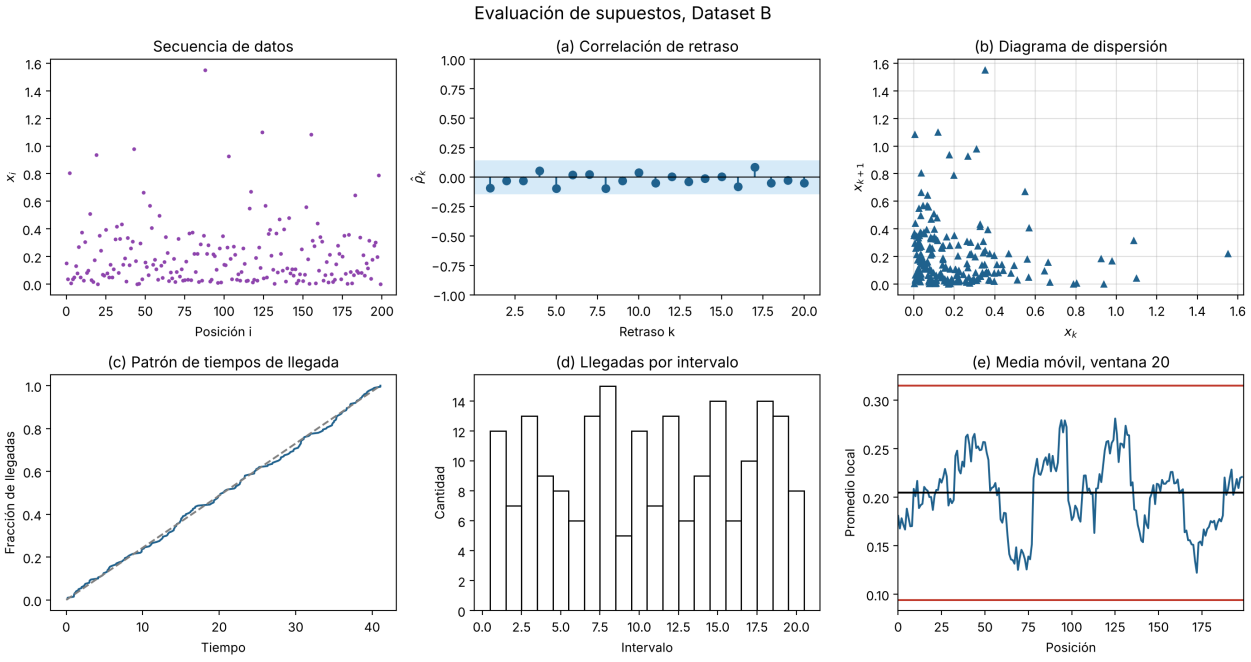


Figura 9. Gráficas de la sección 5.2 para el conjunto B.

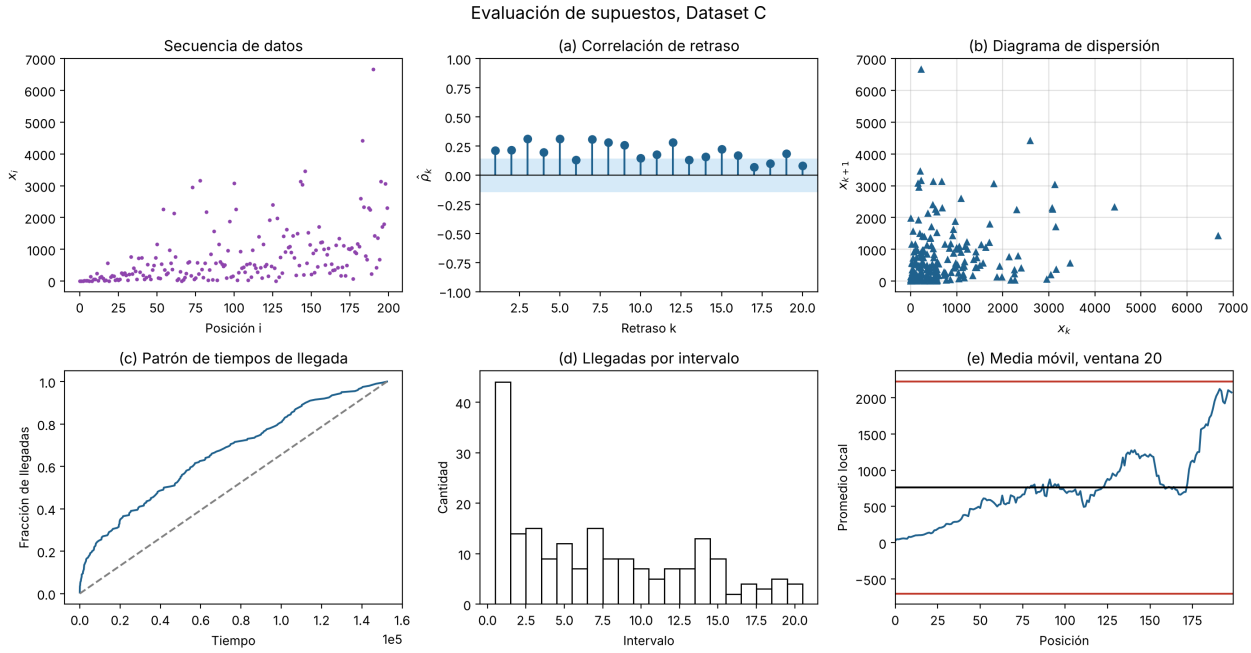


Figura 10. Gráficas de la sección 5.2 para el conjunto C.

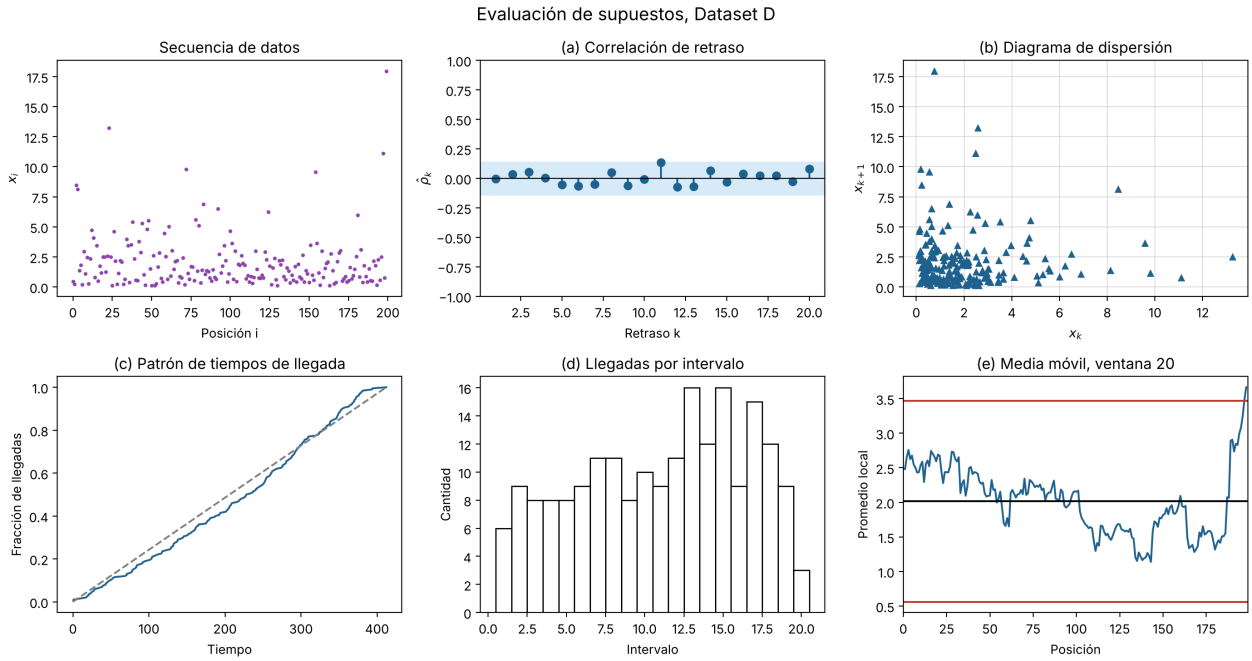


Figura 11. Gráficas de la sección 5.2 para el conjunto D.